

第一章 认识人工智能



重点

三四五章最重点

一、人工智能的基本概念

三个层面 {

- 计算智能
- 感知智能
- 认知智能

人工智能的定义：能够模拟、延伸和扩展人类智能的理论、方法、技术及应用系统的一门新的技术科学、实现某些“机器思维”

学习能力（数据驱动训练）

创造力（数据缝合—模式混合+风格迁移）

容错能力（数据洁癖）

伦理决策（损失函数：效率 > 道德）

社交智能（权衡利益）

进化机制（分钟级）

二、人工智能的发展简史

早期探索阶段（1956-1970s）

第一次低谷期（1960s-1970s）

专家系统阶段（1970s-1980s）

机器学习阶段（1980s-1990s）

深度学习与大数据时代（2000s-至今）

早期探索阶段

符号主义、连接主义、行为主义

以符号与逻辑为核心特征

专家系统阶段

专家系统核心架构：知识库和推理机

专家系统与LISP计算机被视为人工智能真兴的标志

神经网络的起源 —— 感知机

- 局限性：① 无法解决异或门
② 电脑不能支撑超大计算量

神经网络之父 Geoffrey Hinton

分布式表征：存储效率高，鲁棒性好

提出适用于多层感知机 (MLP) 的反向传播算法

神经网络的研究开始复苏

卷积神经网络 (CNN)

专门为处理图像而设计的神经网络

深度学习与大数据时代

深度学习的兴起依赖于 { 海量数据
GPU 算力
算法优化

CPU 受限于串行架构与有限核心数

GPU (图形处理器) 的海量计算核心天然契合神经网络中的矩阵运算需求

算法突破 { ReLU 激活函数
Dropout 正则化技术
Adam 优化器

三, 人工智能的分类与主要学派

按智能水平分类 { 弱人工智能
强人工智能
专用人工智能
通用人工智能

按研究领域 { 机器学习
模式识别
深度学习
.....

弱人工智能定义：指专门设计用于自动化需要特定认知技能的任务的 AI 应用程序，没有自我意识或通用理解能力

强人工智能定义：具有高效的学习和泛化能力，有独立意志，能在设计的程序范围外自主决策并采取行动的人工智能

专用人工智能(狭义人工智能): 特定于应用程序或任务的人工智能

通用人工智能(深度人工智能): 能够思考, 理解、学习和应用其智能来解决复杂问题


“强弱”侧重具备意识, “通用/专用”侧重功能通用

人工智能主要学派

符号主义学派, 连接主义学派, 行为主义学派

学习模式	优势	不足
符号主义 (用规则教)	与人类逻辑推理相似, 逻辑严谨、解释性强	难以构建完备的知识规则库, 处理不确定性和复杂环境能力弱
连结主义 (用数据学)	直接从数据中学, 模式识别和学习能力强	以深度学习为例: 依赖于数据、解释性不强
行为主义 (用问题引导)	从经验中进行能力的持续提升, 直接高效、适用于复杂环境	非穷举式搜索而需更好策略; 容易陷入“经验主义”, 缺乏对智能本质的深入刻画

四、人工智能的主要研究领域和应用



机器学习: 一种通过算法和模型使计算机从数据中自动学习并进行预测或决策的技术, 涵盖监督学习、无监督学习和强化学习等范式, 依赖于工设计特征进行模型训练

经典算法: 线性回归、K-最近邻, 支持向量和、聚类、决策树、随机森林

深度学习: 特指基于深层神经网络模型和方法的机器学习技术, 通过多层神经网络自动提取高阶特征, 依托大规模数据与高性能计算实现端到端学习。

强化学习: 智能体如何采取行动以适应环境, 从而最大化某种累积奖励

基本要素: 奖励, 价值, 环境、模型

应用: 自动驾驶, 游戏对抗

自然语言处理 { 自然语言理解
自然语言生成

应用: 机器翻译, 信息抽取, 问答系统, 情感分析

计算机视觉: 使用计算机及相关设备对生物视觉的一种模拟, 用机器代替人的眼睛对目标进行识别、跟踪和测量等

应用: 人脸识别, 自动驾驶、图像修复、目标检测

语音技术 { 语音识别
语音合成

应用: 实时语音转录, 教学工具

模态融合

知识图谱: 将现实世界的对象和概念以及它们之间的多种关系以图结构的方式组织起来

应用: 搜索引擎、推荐系统

具身智能: 智能体通过身体与环境的互动产生的智能行为
与强化学习紧密相关


情感计算

生成式人工智能

第二章 人工智能中的数据表示 几乎都是重点

核心：把原始数据编码成数字序列或向量，用于量化和计算

一、文本表示



Token: 具体形态由分词算法或分词器决定

捕获有意义的子词或词汇单元

减少序列长度，提高计算效率

Token是自然语言与神经网络之间的桥梁

决定模型语义理解粒度、上下文窗口边界及计算成本


■ 分词器是如何工作的？

以BPE (Byte Pair Encoding, 字节对编码) 算法为例：

1. 初始时将文本拆分为最小单元，如单字符（字母、数字和标点符号）
2. 从字符开始，计算所有相邻字符对的共现频率，找到频率最高的一对进行合并成新 token，这个新符号成为词汇表中的一个新条目（子词）
3. 重复合并过程，直到达到预设的词汇表大小
4. 分词时，按“从长到短”匹配生成的子词表，无法匹配的则拆分为更小的子词/字符。
5. 映射为词表 ID：将每个 token 转换为模型词表中对应的唯一整数 ID，这是因为模型无法直接处理文本 token，只能处理整数 ID；

词向量的编码方法—独热码

Word 2 Vec 模型：一种浅层神经网络模型，把语义相似的词映射到向量空间中相近的位置



二、音频表示

音频特征提取

声音通过采样、量化、编码，获得了声波图（时间—幅度）

通过傅里叶变换，得到频谱图（频率—能量）

傅里叶变换：一个信号可以表示为许多不同频率和强度的信号的叠加


语谱图：通过傅里叶变换得到的时间—频率能量分布图

应用：AI 语音合成、AI 降噪、语音增强、语音分离，说话人分离

■ 音频特征提取——MFCC（梅尔频率倒谱系数）

■ 语音信号处理中最常用、最核心的特征提取方法之一

■ 提取出符合人耳听觉感知特性的特征向量，用于语音识别等任务。



三、图像与视频表示

图像可以看作一个由像素值组成的矩阵

彩色图像的表示：彩色图像分为三层，为红色通道(R)、绿色通道(G)、蓝色通道(B)，像素值的范围都是0~255

一张彩色图像看作是一个三维矩阵

计算机理解图像的基础：图像的矩阵表示

卷积神经网络依赖一系列的矩阵运算

应用：图像处理、图像分类、目标检测、图生、图像问答，文生图

视频表示：视觉暂留原理

应用：人体姿态估计、摔倒检测、高空抛物检测，AI 视频生成

四、图结构表示

欧几里得表示：数据存在“规则的组织结构”

但并非所有数据都可以表示为规则的序列或网格

图的基本类型

无向图，有向图

无向完全图 $\frac{n(n-1)}{2}$ 条边，有向完全图 $n(n-1)$ 条边

带权图（网络）

图的基本术语

邻接顶点, 关联

顶点的度

路径、路径长度



图的存储表示

邻接矩阵

无向图的邻接矩阵是对称的, 有向图的邻接矩阵可能是不对称的

无向图中, 第 i 行 1 的个数为顶点 i 的度

有向图中, 第 i 行的个数为顶点 i 的出度

第 j 列 1 的个数为顶点的入度

带权图的邻接矩阵

$$A. \text{Edge}[i][j] = \begin{cases} W(i,j), & i \neq j \text{ 且 } \langle i,j \rangle \in E \text{ 或 } (i,j) \in E \\ \infty, & i \neq j \text{ 且 } \langle i,j \rangle \notin E \text{ 或 } (i,j) \notin E \\ 0, & i = j \end{cases}$$

邻接表

无向图的邻接表

有向图的邻接表(出边表)和逆邻接表(入边表)

带权图的邻接表

人工智能中的图表示学习

定义: 通过算法将图中的节点、边、子图或整个图转换为低维

向量表示, 并尽可能保留原始图的结构和语义信息

通过学习得到的向量表示, 可以作为输入送进神经

网络或其他算法, 用于分类、预测、推荐等任务

节点表示学习: 将每个节点映射为低维向量, 向量需反映

节点的连接模式和属性

目标: 节点之间嵌入的相似性近似于它们在网络中的相似性

如何进行? 图卷积神经网络

借鉴卷积网络、循环网络和深度自动编码器等的思想,

定义, 设计用于处理图数据的神经网络结构

难点: 如何在图中传播信息以计算节点特征


如愿





图卷积核心思想: 利用“边的信息”对“节点信息”进行“聚合”, 从而生成新的节点表示


(1) 邻居节点聚合 (2) 节点向量更新



“我更新自己的表示时, 会看一看我连接的邻居节点, 把它们的信息融合进来。”

应用: 社交网络分析、电商与推荐系统、生物医学与药物研发、
交通与城市计算

五、三维数据表示



常用表示形式 {
多视角图像
深度图
体素
点云
多边形网格

三维数据表示学习基本思想

在规则数据上应用2D/3D 卷积神经网络 CNN

在非规则数据(点云、多边形网络)上可应用图卷积神经网络
GCNN

第三章 符号主义人工智能

一、符号主义简介


定义：符号主义人工智能是人工智能研究中的一个集合术语，泛指所有“基于问题、逻辑和搜索的高级符号（人类可读）表征”的方法
所谓符号就是模式

符号主义观点：

- 1. 人工智能源于数理逻辑
- 2. 人工智能的研究方法应为功能模拟方法

优势：逻辑规则的清晰和易解释性、技术可控性

缺陷：处理模糊性和歧义的低限性、依赖于手动编码的知识库




二、状态空间搜索

■ 状态空间搜索是符号主义人工智能中最基本的问题求解方法。它通过把问题抽象为状态与动作，将所有可能的状态及其相互转换关系构成一个状态空间。在这一空间中，求解问题就转化为从初始状态出发，经过一系列动作，找到一条能够到达目标状态的路径。


一个搜索问题由六个要素组成：

初始状态、状态空间、目标状态、动作、代价、状态转移



搜索问题的解

解是末状态属于目标状态的动作序列, 路径的总代价由沿途每个动作的代价累加而成



搜索算法: 穷举出一个问题的部分或所有可能情况找出求解方法

无信息搜索 (非启发式搜索)


- 广度优先算法: 在有限状态空间中是完备的 在动作未加权时是最优的 适用于搜索最短路径的解
- 深度优先算法: 在有限状态空间中是完备的 适用于搜索全部的解
- 代价一致搜索: 在 BFS 的基础上, 考虑了代价的扩展 总是扩展路径消耗最小的节点

启发式搜索

- 贪婪搜索 (贪心算法): 当前状态上最好或最优的选择 不完备, 非最优, 依赖于启发函数 $h(x)$
- A* 搜索: 结合了贪婪搜索和代价一致算法 完备, 最优 (当 $f(n) = g(n) + 0$)

$f(n) = g(n) + h(n)$ 估值函数

- 当前代价函数 $g(n)$ 表示从初始状态到当前状态 n 的代价值。
- 启发式函数 $h(n)$ 表示从当前状态 n 到目标状态的代价的估计。
- 评价函数 $f(n)$ 可视为经过状态 n 、具有最小代价值的路径。



A* 搜索与其他搜索比较

	Greedy Search	UCS	A* Search
计算方式	只考虑目标方向, 不考虑已走过的路径	只考虑路径代价, 不考虑目标方向	既考虑目标方向, 也考虑路径代价
速度	快, 容易陷入局部最优	取决于代价分布	稍慢, 但更可靠
结果	可能找到次优解或死胡同	一定能找到最优解	能找到最优解 (如果 $h(n)$ 可采纳)
适用场景	适用于简单、目标明显的搜索	适用于代价不同但无启发信息的搜索问题	适用于复杂路径优化问题

对抗搜索(博弈搜索)




最小最大搜索: 最小化对手在我方选择最好策略后的最大可能获益
Alpha-Beta 剪枝搜索: 剪除最小最大搜索的一些没有必要的搜索分支

Alpha值(α)	玩家MAX(根节点)目前得到的最高收益
	假设n是MIN节点, 如果n的一个后续节点可提供的收益小于 α , 则n及其后续节点可被剪枝
Beta值(β)	玩家MIN目前给对手的最小收益
	假设n是MAX节点, 如果n的一个后续节点可获得收益大于 β , 则n及其后续节点可被剪枝
α 和 β 的值初始化分别设置为 $-\infty$ 和 ∞	

蒙特卡洛搜索: 从一个节点出发, 进行大量模拟, 记录赢的次数。
但是算力资源是有限的, 把资源放在更值得搜索的分枝上, 即算力集中在更有价值的地方。

■ 蒙特卡洛搜索主要分为四个步骤, 分别为 选择、扩展、模拟、回溯。



三、知识表示

常见的知识表示方法 { 一阶谓词逻辑表示方法
产生式规则表示 if... then... (动物识别系统)
框架表示
语义网络
知识图谱



(会判断即可)

四、逻辑与推理

演绎推理

从一般到特殊的逻辑推理, 通过一定逻辑推导—演绎—得出具体结论的过程。常见有: 三段论, 假言推理, 选言推理, 关系推理

三段论

大前提 + 小前提 → 结论

例: 学生要上课听讲。你是学生。你要上课听讲。

假言推理 (if-then 命题)

又称条件判断。

分为：充分条件假言推理，必要条件假言推理，充分必要条件假言推理

选言推理

选言命题是反映事物的若干种情况或性质至少有一种存在的命题

相容选言命题推理：选言支是可以并存的

不相容选言命题推理：选言支是唯一的

归纳推理 (归结原理方法)

从个别到一般的推理

类比推理

根据两个对象在某些属性上相同或相似，由特殊到特殊，通过比较而推断出它们在其他属性上也相同的推理过程

不确定性推理

从不确定性初始证据出发，通过运用不确定性的知识，最终推出合理或者近乎合理的不确定性结论的思维过程



例：贝叶斯网络推理



五、专家系统

专家系统是在某一特定领域中，通过编码大量特定领域的知识和规则，模仿人类专家的决策过程来解决复杂问题的计算机软件系统，需要通过一定的知识获取方法，将专家知识保存在知识库中，然后运用推理机，从已知事实推导出新的结论

基本结构：人机交互界面，推理机、解释器、知识库、综合数据库、知识获取



知识库：用于存储某领域专家系统的专门知识

推理机：专家系统的大脑，针对当前问题的条件，从知识库中选择知识。

推理和导出结论。常用推理方法：正向推理、逆向推理

专家系统

的分类

确定性推理专家系统

不确定性推理专家系统

(不确定性推理通常用置信度方法)

- 用 $CF(A)$ 表示事实 A 为真的置信度，是一个取值范围在 $[-1, 1]$ 的浮点数
- 当 $CF(A) = 1$ 时，表示 A 肯定为真
 - 当 $CF(A) = -1$ 时，表示 A 为真的置信度为 -1 ，也就是 A 肯定为假
 - $CF(A) > 0$ 表示 A 以一定的置信度为真
 - $CF(A) < 0$ 表示 A 为真的置信度为负，即其为假的置信度为 $-CF(A)$
 - $CF(A) = 0$ 表示对 A 一无所知。一般当 $CF(A)$ 取值为一个绝对值较小的区间时，即认为系统不包含任何 A 的相关信息

专家系统与传统程序设计的区别：


项 目	传统的程序系统	专家系统
处理对象	数字	符号
编程思想	数据结构+算法	知识+推理
求解知识	隐含于程序中	知识存于知识库中
解释功能	不具有解释功能	具有解释功能
产生结果	正确的答案	有时产生错误答案
处理方法	算法	启发式
处理方式	批处理	交互式
系统结构	数据和控制集成	知识和控制分离
系统修改	难	易
信息类型	确定性	不确定性
处理结果	最优解	可接受解
适用范围	无限制	封闭

应用：智能客服、智能家居系统、MYCIN系统

第四章 机器学习基础

一、机器学习的核心思想

概念：机器学习并不是某一个具体的算法，而是一类让计算机能够从数据中自动学习规律并进行预测的方法



机器学习三要素 { 数据
模型
目标函数/策略

数据是机器学习的原材料，特征是对数据的一种描述，是从原始数据中提取出来的，能够反映数据特点和规律的信息

模型是学习的对象，定义了输入与输出之间的关系

简单模型：逻辑回归，决策树...

复杂模型：神经网络，支持向量机...

目标函数是一个数学函数通过计算一个数值来衡量模型预测结果和真实结果之间的差异，引导模型不断优化

机器学习流程

1. 收集数据
2. 数据准备 (把数据分成：训练组 + 验证组 + 测试组)
3. 选择模型
4. 训练
5. 评估 (用验证/测试集给模型打分)
6. 参数调整
7. 预测

二、机器学习的主要类别



{ 监督学习
无监督学习
强化学习

监督学习

提供答案，学习特征与标签之间的关系

应用：语音识别，图像识别，自然语言处理

问题：对标注数据要求较高

训练阶段：带标签的输入数据

监督学习模型：通过学习带标签数据，掌握分类的特征规律

预测阶段：对新的无标签数据分类

lxy-bnu

本质：目标导向，学习输入与输出之间的映射关系，在预测阶段对未知数据进行分类或回归

无监督学习

不提供答案，自己发现规律

应用：客户分群、对复杂数据进行降维等

问题：机器自己定义“好结果”，可能和人类并不对齐

训练阶段：无标签的输入数据

无监督学习模型：发现数据结构与分布规律，靠自主识别数据里的模式、聚类规律来学习

预测阶段：对新无标签数据分类

本质：数据驱动，无需人工标签，从数据中挖掘内在规律

强化学习

在环境中试错，通过正确动作获奖励来学习最优策略

应用：游戏 AI、自动驾驶系统、机器人控制等

问题：强化学习可能存在因面向特定任务而泛化性低、因环境复杂而难以收敛等问题

本质：目标导向，无需人工标注数据，自主学习完成复杂任务

优势：从环境中自主学习，潜力可超人类


现代智能系统往往结合三者优点形成“混合学习范式”



三、常见机器学习算法

(不会计算)
(判断类型)

监督学习算法：回归，决策树，分类，集成学习



回归

线性回归

{ 简单线性回归
多元线性回归

简单线性回归

最小二乘法：计算出使得纵同差值平方和最小的 k 和 b

定义残差平方和函数

$$L(k, b) = \sum_{i=1}^n (y_i - (kx_i + b))^2$$

分别对 k 和 b 求偏导并令其为 0
目的：找到令这个平方和最小的 k 和 b

$$\begin{cases} \frac{\partial L}{\partial k} = -2 \sum x_i (y_i - kx_i - b) = 0 \\ \frac{\partial L}{\partial b} = -2 \sum (y_i - kx_i - b) = 0 \end{cases}$$

整理可得 k 和 b 的表达式

$$\begin{cases} k = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} \\ b = \bar{y} - k\bar{x} \end{cases}$$

优点：精确、计算简单，但当样本维度高、数据量大时，求逆计算量非常大

迭代法：通过迭代逼近最优 k 和 b

1. 随机选取初始 k 和 b ，画出一条初始直线
2. 定义损失函数（如均方误差）来衡量预测值与真实值的差距
3. 每次迭代沿着损失下降最快的方向更新参数
4. 当损失变化趋于稳定时，算法收敛，得到一条最佳拟合直线

优点：计算复杂度可控，更灵活

多元线性回归

基于多个自变量 ($x_1, x_2, \dots, x_n$) 与因变量 (y) 的线性关系

构建模型 $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$

实现对未知 y 的预测 (β 为系数, ϵ 为误差项)

实例：房价预测，热度预测

线性回归的局限性

1. 强依赖线性关系
2. 对异常值敏感


逻辑回归

$\begin{cases} \text{单特征} \\ \text{多特征} \end{cases}$

单特征

用线性函数建模输入与输出关系再用 Sigmoid 函数把结果映射成概率，实现二分类

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



多特征

- 给每个特征一个重要性分数, 把“特征值 $\times$ 重要性分数”加起来, 得到一个总线索值, 再把总线索值放进 Sigmoid 曲线, 算出最终的概率
- 需要一个阈值 (默认 0.5, 可以根据场景调整)
 - 概率 $>$ 阈值 判定为“是”
 - 概率 $<$ 阈值 判定为“否”

实例: 肿瘤大小预测良恶性, 预测用户产品类购买偏好

决策树

明确最终目标和可能结果, 找出关键判断问题, 排顺序, 把问题和结果连成树


优点: 直观易懂, 数据兼容性强, 自动筛无关特征, 高效实用

缺点: “想过多”过拟合, 忽略特征交互关联、算法固有偏向性

分类

对各种事物分门别类, 用于离散型预测

{ 支持向量机
K近邻算法



支持向量机

支持向量机 (SVM) 就是找一条线, 这条线不仅能分开两堆东西, 还能让线到两堆东西的 **距离都最大**

支持向量: 两堆里最拼命靠近的数据

最大间隔: 线要站在正中间

SVM 的核心就是最大化这个间隔

如果数据在低维分不开, 需要用 **核函数** 把东西举到更高维去分
找到一个 **超平面** (高维度的面), 让它到两堆东西的支持向量间隔最大

应用: 人脸识别

优点: 理论坚实、几何直观, 小样本学习优势显著,

能有效处理高维数据, 高效泛化与轻量依赖

缺点: 大规模数据效率瓶颈, 参数敏感, 需要调参

核函数选择需经验, 对缺失数据和噪声比较敏感



K近邻算法

核心思想: 通过计算待分类样本与训练集中各个样本的距离, 找到**距离最近的 K 个样本**, 然后根据这 K 个样本的类别或值来预测待分类样本的类别或值

本质: 通过观察一个人最亲近的朋友的喜好来推测他的喜好

优点: 无复杂训练过程, 支持多任务, 灵活性强

适应小样本, 对异常值鲁棒性较强


缺点: 数据量大时效率极低, 对无关特征敏感

K 值选择依赖经验, 高维数据下距离失效

集成学习

通过结合多个弱学习器来构建一个强学习器, 提升模型性能

{ Bagging
Boosting



Bagging

通过自助采样法生成多个训练集, 然后分别训练多个模型, 最后通过投票或平均的方式得到最终结果


典型算法: 随机森林

Boosting


通过迭代的方式训练多个模型, 每个模型都试图纠正前一个模型的错误, 最终通过加权投票的方式得到结果

典型算法: AdaBoost


无监督学习算法: 聚类、降维、关联规则学习



(a) 聚类



(b) 降维



(c) 关联规则学习



聚类


依靠数据本身的相似性，实现自动分组

- K-means (k均值)
- 层次聚类
- DBSCAN

K-means

K 为聚成的簇的数量, means 表示均值


通过计算数据点之间的距离，将数据划分到距离某个中心点（簇内所有数据点的均值）最近的簇中



层次聚类

层次聚类是基于距离的聚类方法
通过计算数据点之间的相似性（或距离）构建一个嵌套的聚类树状结构。

在聚类树中，不同类别的原始数据点是树的最低层，树的顶层是一个聚类的根节点



聚合型层次聚类


自底向上合并，把数据集中的每个对象做为一个簇开始，迭代地把簇合并成为更大的簇，直到最终形成一个大簇，或者满足某个终止条件

分裂型层次聚类

自顶向下拆分，把所有对象放入一个簇中开始，该簇是层次结构的根。然后把根上的簇用 K-means 算法划分为多个较小的子簇，并且递归地继续划分，直到满足终止条件

DBSCAN

DBSCAN 是基于密度的聚类算法
它将簇定义为密度相连的点的最大集合，能够把具有足够高密度的区域划分为簇，并可在有噪声的空间数据库中发现任意形状的聚类



K-means	优 简单高效 聚类效果好 可解释性强	缺 需预设 K 值 对初始簇中心敏感 对异常值敏感
层次聚类	无需预设聚类数 聚类结果可视化好 适用范围广	计算复杂度高 聚类结果不可逆 缺乏全局优化
DBSCAN	无需预设聚类数 能识别噪声点 发现任意形状簇	参数选择困难 计算复杂度高 对密度变化适应差



降维

把高维度的复杂数据压缩成低纬度的简单数据,同时保留最关键的信息

- 主成分分析 (PCA)
- 线性判别分析 (LDA)
- t-SNE

主成分分析 (PCA)

无监督地找出数据中最主要的方向(主成分),将数据投影到这些方向上,实现降维

数学基础: 数据协方差矩阵的特征值、特征向量

应用: 图像压缩, 人脸识别

线性判别分析 (LDA)

LDA 是一种有监督的降维方法, 它的目标是找到一个投影方向, 使得不同类别的数据点尽可能分开, 同一类别数据点尽可能聚集。在降维的同时, 最大化类间距离、最小化类内距离

t 分布随机邻域嵌入 (t-SNE)

一种非线性降维算法, 常用于可视化高维数据。无监督地构建高维概率分布, 通过在高维和低维空间中同时保持样本之间的邻近概率分布, 使相似的数据点在低维空间中仍然靠近, 不相似的点远离

	优点	缺点
LDA	有监督分类友好 维度上限明确 线性场景下鲁棒性强	依赖标签 仅线性降维 对小样本/高维数据不友好
PCA	无监督通用 计算高效、可解释性强 去冗余效果好	仅线性降维 无类别感知 对噪声敏感
t-SNE	非线性降维能力强 可视化效果极佳 局部结构保留好	计算复杂度高 不可复现性、参数敏感 全局结构失真

关联规则学习

发现未标注数据集的变量之间的关联

流程: 1、喂数据, 算法探索规律
2、人类解读规律指导决策

经典算法: Apriori 算法、FP-Growth 算法

强化学习：回顾、Q-Learning



- 强化学习的核心：通过试错→得奖励 / 惩罚→记经验学会做决策。
- 智能体 (Agent)
 - 决策主体，执行动作、接收反馈、更新策略
- 环境 (Environment)
 - 智能体互动的外部世界，接收动作、返回状态 + 奖励
- 状态 (State, S)
 - 环境的当前情况，告诉智能体现在处于什么场景
- 动作 (Action, A)
 - 智能体能做的操作，智能体改变环境的手段
- 奖励 (Reward, R)
 - 环境的反馈打分，指导智能体什么是对 / 错

回顾

五要素的互动逻辑是**循环的**


智能体(看状态)→选动作→环境(变状态)→给奖励→智能体(根据奖励更新策略)→再选动作 ... 直到目标达成

Q-Learning

强化学习中的一种经典算法，属于无模型值迭代方法，用于让智能体在环境中通过试错学习，更新动作价值函数(Q 值)不断逼近最优策略

迷宫寻路问题

不断重复“选择动作→移动→获得奖励→更新 Q 值”过程，直到停止学习。随着学习推进，Q 表会越来越准确，老鼠就能根据 Q 表选择 Q 值最大的动作，从而更高效地避开地雷、收集闪电、快速回家。




对比维度	监督学习	无监督学习	强化学习
数据需求	有特征 + 标签的配对数据	只有特征，无标签	无标准答案，只有环境的奖励反馈
学习逻辑	学习特征→标签的映射规律	自己找数据内在规律	学习状态→动作的策略
典型场景	图片分类 房价预测 疾病诊断	用户分群 数据压缩 购物篮分析	游戏 AI 机器人控制 自动驾驶

第五章 深度神经网络

人工智能、机器学习、深度学习

- 人工智能（AI）包含机器学习（ML）和深度学习（DL），深度学习又是机器学习的一个分支，更加关注神经网络。



重要推动力量

- GPU计算性能的提升端到端训练
- 大规模标注数据集的出现
- 训练难题的不断解决
 - 端到端训练
 - 梯度消失
 - 参数初始化
 - 深层网络模型

定义：神经网络是由多层可训练神经元经加权连接构成的计算模型，通过逐层非线性变换将输入特征映射至输出空间，具备通用函数近似能力

人工神经网络 { 神经元的基本架构
层次结构
学习机制



神经元的基本架构：主要指神经元输入到输出之间的关系，一般为非线性函数

层次结构：网络按输入层、多级隐藏层与输出层分级排列，形成深度结构，实现具体到抽象的特征提取

学习机制：利用梯度信息迭代更新权重与偏置，最小化损失函数

一、神经元的基本架构


人工神经网络：

输入 x

加权求和

激活函数输出 y

MCP模型结构 [McCulloch 1943]



给定 n 个二值化（0或1）的输入数据 $x_i (1 \leq i \leq n)$ 与连接参数 $w_i (1 \leq i \leq n)$ ，MCP神经元模型对输入数据线性加权求和，然后使用函数 $\Phi(\cdot)$ 将加权累加结果映射为0或1，以完成两类分类的任务：


$$y = \Phi\left(\sum_{i=1}^n w_i x_i\right)$$

其中 w_i 为预先设定的连接权重值（一般在0和1中一个值或者1和-1中取一个值），用来表示其所对应输入数据对输出结果的影响（即权重）。 $\Phi(\cdot)$ 将输入端数据与连接权重所得线性加权累加结果与预先设定阈值 θ 进行比较，根据比较结果输出1或0。

单个神经元的内部结构

神经网络中的神经元接收来自外部的若干个变量值为每个变量值赋予不同的权重，对变量进行加权求和，并经过内部激活函数的处理，最终输出激活函数的处理结果

- 输入 x ：神经元的输入变量值，可以理解为上一层神经元的输出结果。
- 权重 w ：每一个输入对应着一个权重，代表着该输入的重要程度，重要程度越高，则权重越大。
- 偏置 b ：让神经元的激活阈值更加灵活，帮助网络在输入为零时仍能产生有效输出，从而增强模型的拟合和泛化能力。
- 激活函数 f ：当输入激励达到一定强度，神经元就会被激活，产生输出信号。模拟这一细胞激活过程的函数，就叫激活函数。
- 输出 y ：激活函数的输出结果，不同的激活函数有着不同的输出结果。




权重与偏置的作用：

直线 $y = wx + b$ 上方为激活区，下方为抑制区

w 值越大对输入变化响应越敏感

b 值越大激活条件越严格

局限性：线性模型 $w_1x_1 + w_2x_2 + c$ 能解决与、或、非问题，但无法（单层感知器）处理异或这类非线性问题



激活函数

线性变换后接入非线性激活


性质要求：连续可导，尽可能简单，导数值域不能太大或太小

- Sigmoid型函数指一类S型曲线函数，为两端饱和函数


- Logistic函数

$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

- 具有“挤压”功能
- 输出可看作概率分布



Logistic函数



Logistic函数的导数


- Tanh函数（双曲正切函数）

$$\begin{aligned} \tanh(x) &= \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)} \\ &= 2\sigma(2x) - 1 \end{aligned}$$

- 零中心化，输出范围是 $(-1, 1)$ ，
- 通常能使训练过程收敛得更快。



Tanh函数





Tanh函数的导数

■ Relu函数

$Relu(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} = \max(0, x)$

- 是目前最常用的激活函数
- 具有单侧抑制（只有当输入信号为正时，神经元才被激活）、宽兴奋边界（激活后，输出信号的强度会随输入线性增加）的生物学合理性
- 可缓解梯度消失问题
- 缺点：有可能导致神经元的死亡（某个神经元在训练过程中，无论输入什么数据，它的输出始终是 0，再也不会被激活。）



二、层次结构


单层感知机

早期的感知机结构由一个输入层和一个输出层构成。感知机的输入层负责接收实数值的输入向量，输出层则能输出1或-1两个值



多层感知机（前馈神经网络）

最早发明的简单人工神经网络，通过引入一个或多个隐藏层和非线性的激活函数，获得强大的非线性映射能力



$a^{(l)} = f_l(W^{(l)}a^{(l-1)} + b^{(l)})$

输入样本沿既定路径逐层运算，生成输出，即前向传播：

- step1：输入的加权求和与偏置
- step2：激活函数的应用
- step3：输出层的计算

记号	含义
L	神经网络的层数
M_l	第 l 层神经元的个数 ($1 \leq l \leq L$)
$f_l(\cdot)$	第 l 层神经元的激活函数
$W^{(l)} \in \mathbb{R}^{M_l \times M_{l-1}}$	第 $l-1$ 层到第 l 层的权重矩阵
$b^{(l)} \in \mathbb{R}^{M_l}$	第 $l-1$ 层到第 l 层的偏置
$z^{(l)} \in \mathbb{R}^{M_l}$	第 l 层神经元的净输入（净活性值）
$a^{(l)} \in \mathbb{R}^{M_l}$	第 l 层神经元的输出（活性值）

三、学习机制

神经网络的表达能力源于层级非线性变换对特征空间的逐级重参数化

损失函数



定义：损失函数又称为代价函数，用来计算模型预测值与真实值之间的误差

- 两种最常用损失函数
- 均方误差损失函数
 - 交叉熵损失函数

*交叉熵越小两个概率分布 P 和 Q 越接近

梯度下降

用于求解无约束最优化问题


算法原理：通过沿着当前点的梯度反方向更新参数，以减少目标函数值。

迭代过程：从初始参数开始，计算损失函数在当前参数下的梯度，根据梯度方向更新参数，重复直至收敛



学习率 α ：梯度下降的超参数，控制每次迭代对参数 w/b 的更新步长

α 过大：不收敛； α 过小：收敛太慢



策略 { 批量梯度下降法
随机梯度下降法
小批量随机梯度下降法

过拟合 vs 欠拟合

欠拟合

训练误差高


模型容量不足 or 训练轮次太少

过拟合


训练误差持续降低，验证误差反而上升

模型记忆噪声，新数据表现差


分类 (Classification) 问题中三种拟合状态



欠拟合




好的拟合



过拟合

四、卷积神经网络 (CNN)



卷积运算

定义：卷积是分析数学中一种重要的运算。在信号处理或图像处理中经常使用一维或二维卷积

卷积操作 $\rightarrow$ 滤波操作，卷积核 $\rightarrow$ 滤波器


步长 S ：卷积核在滑动时的时间间隔

零填充 P ：在输入向量两端进行补零


给定一个输入信息 X 和滤波器 W 的二维卷积定义为：

$$Y = W * X$$

其中 $*$ 表示二维卷积运算。




$$2 \cdot 1 + (-1) \cdot (-2) + 1 = 5$$



$$(-1) \cdot 2 + 1 \cdot (-1) + 1 = -2$$

均值滤波就是一种二维卷积，将当前位置的像素值设为滤波器窗口中所有像素的平均值，即 $W_{uv} = \frac{1}{uv}$

一幅图像经过卷积后得到结果称为**特征映射**



高斯滤波器
平滑去噪

提取边缘特征

卷积输出的特征大小计算公式:

$$W_2 = (W_1 - F + 2P) / S + 1$$

$$H_2 = (H_1 - F + 2P) / S + 1$$

W_2 是卷积后特征图的宽度

W_1 是卷积前图像的宽度

H_2 是卷积后图像的高度

H_1 是卷积前图像的高度

F 是滤波器的宽度

S 是步长

P 是零填充的数量

卷积的动机

全连接网络参数量随着输入图像尺寸增长而爆炸式增长

局部连接网络卷积层与下一层之间的连接数大大减少,由 $M_1 \times M_2$ 个变为 $M_1 \times K$ 个连接, K 为卷积核大小



权重共享:

1. 作为参数的**卷积核** $w(l)$ 对于第 l 层的所有神经元都是**相同的**
2. 使用相同权重参数在不同位置卷积,可以有效发现图像中的**相似模式**
3. 一个卷积核只捕捉输入数据中的**一种特定的局部特征**,如果要提取多种特征就需使用多个不同的卷积核



池化


定义: 池化是对每个区域进行下采样得到一个值,作为这个区域的概括

作用: 池化层也叫**下采样层**。其作用是进行**特征选择**,降低特征数量,从而**减少参数数量**。通过缩小特征图、提取更稳定的关键信息,使模型更抗噪、更高效、泛化能力更强

最大池化: 对于一个区域 $R_{m,n}^d$, 选择这个区域内所有神经元的最大活性值作为这个区域的表示

平均池化: 一般取区域内所有神经元活性值的平均值

lxy-bnu




池化与卷积的不同作用:

卷积用于特征提取与特征学习

平均池化用于保留整体信息: 背景信息

最大池化用于选择高响应特征: 纹理或边缘



卷积神经网络

卷积层 → 池化层 → 全连接层

提取特征 降维, 防过拟合 输出结果

实例: LeNet-98, AlexNet, VGG-Net


五、循环神经网络 (RNN)

更好地处理序列的信息




定义: 循环神经网络是一类处理序列数据(如文本句子、视频帧等)时所采用的网络结构。

本质: 模拟人所具有的记忆能力, 在学习过程中记住部分已经出现的信息, 并利用所记住的信息影响后续结点输出。




■ 一个简单的循环神经网络由输入层、一个隐藏层和一个输出层组成。



- X 是一个向量, 它表示输入层的值
- S 是一个向量, 它表示隐藏层的值, S 不仅仅取决于当前这次的输入 X , 还取决于上一次隐藏层的值
- O 也是一个向量, 它表示输出层的值
- U 是输入层到隐藏层的权重矩阵
- V 是隐藏层到输出层的权重矩阵
- W 是隐藏层上一次的值作为这一次的输入的权重矩阵
- 去掉有 W 的带箭头的圈, 它就变成普通的全连接神经网络

$$O_t = g(Vs_t), s_t = f(Ux_t + Ws_{t-1})$$

⇒ 输出值 x_t 受前面历次输入值的影响



应用:

编写诗歌

情感分析

自动问答

词性标记

文本分类

机器翻译

第六章 深度学习平台

以下都是划的重点

人工智能计算基础与硬件平台

CPU: 在计算机上运行程序时, 需要将程序、程序使用的数据移到处理器上

CPU 的内核(Core): 在一个芯片上集成多个处理器的技术

- CPU 本身为通用计算设计, 即使是多核 CPU, 也不具有良好的并行性。
 - 原因: 无法在同一时间执行足够多的乘法与加法运算, 速度慢。

- GPU:
- 图形处理器 (Graph Processing Unit, GPU)
 - 是一种专门设计用于大量并行计算的处理器, 是显卡的核心组件。
 - GPU 具有更大内存, 并通过提高向量与矩阵的计算速度, 提升系统整体性能。
 - GPU 的发展来源于电子游戏的发展对显卡提出了高速计算的需求。
 - GPU: 面向图形和并行计算的大规模SIMT(单指令多线程)处理器
 - 不擅长处理稀疏数据(稀疏结构破坏了并行性, 导致大量“无效线程”浪费掉计算资源)
 - 不擅长处理不规则控制流, 如中断、分支 (GPU线程只能执行同一条指令)

CUDA: ■ CUDA (Compute Unified Device Architecture) 是 NVIDIA 开发的一套软件 + 编程模型, 让程序员可以用 C/C++ 风格的代码控制 GPU 来做通用计算。



- TPU: ■ Google 公司设计了专门服务于人工智能的芯片 TPU (Tensor Processing Unit)。
- 专门为深度学习矩阵乘法设计的“矩阵乘法专用加速器”
 - TPU 优化矩阵乘法和卷积, 与 GPU 相比, 功耗更低、性能更好。
- GPU是通用并行计算芯片, 兼顾图形与 AI; TPU 是为深度学习矩阵乘法专门优化的专用芯片, 效率和能耗更优但通用性弱。

	Cores	Clock Speed	Memory	Price	Speed
CPU (Intel Core i7-7700k)	10	4.3 GHz	System RAM	\$385	~640 GFLOPs FP32
GPU (NVIDIA RTX 3090)	10496	1.6 GHz	24 GB GDDR6 X	\$1499	~35.6 TFLOPs FP32
GPU (Data Center) NVIDIA A100	6912 CUDA, 432 Tensor	1.5 GHz	40/80 GB HBM2	\$3/hr (GCP)	~9.7 TFLOPs FP64 ~20 TFLOPs FP32 ~312 TFLOPs FP16
TPU Google Cloud TPUv3	2 Matrix Units (MXUs) per core, 4 cores	?	128 GB HBM	\$8/hr (GCP)	~420 TFLOPs (non-standard FP)

CPU: Fewer cores, but each core is much faster and much more capable; great at sequential tasks

GPU: More cores, but each core is much slower and “dumber”; great for parallel tasks


TPU: Specialized hardware for deep learning

第七章 计算机视觉


一、计算机视觉简介

■ 研究人类视觉系统对计算机视觉发展的意义

- 启发各类注意力机制设计，建模实体之间的相关性，优化冗余信息过滤与目标信息聚焦




Attention Mechanism




Squeeze-and-Excitation Module

- 启发多尺度层级设计，使计算机能从粗粒度全局感知（如在大场景中定位目标物体）到细粒度局部解析（如识别物体细节）



- 视觉语义关联，推动计算机视觉从像素识别（如分类、检测）迈向图像理解（如语义分割、行为预测）



二、图像分类

任务目标：将输入的图片归类到预定义的类别中

- 图像是像素构成的数组： $X \in \mathbb{R}^{H \times W \times 3}$
- 对类别进行编号：香蕉→1，苹果→2，橘子→3 等等，得到类别 $y \in \{1, \dots, K\}$ ， K 为类别总数
- 图像分类问题：构建一个可计算实现的函数 $F: \mathbb{R}^{H \times W \times 3} \rightarrow \{1, \dots, K\}$ ，且预测结果符合人类认知




AlexNet (2012), VGG-19 (2014, 轻量化), GoogLeNet (2014) lxy-bnu


残差网络 ResNet (2015), Vision Transformers (2020), ConvNeXt (2020)

精度退化问题

- 现象：模型层数增加到一定程度后，训练准确率和测试准确率不降反升
- 注意：这不是因为过拟合，因为如果是过拟合，训练误差会很低而测试误差很高；退化是训练误差本身就很高，表明优化器无法有效地训练更深的网络。



- 本质：随着层数增加，网络学习到的特征可能变得过于稀疏或不具备足够的区分度，深层网络实际上难以学习到一个等价或优于浅层网络的恒等映射 ($y=I(x)=x$)。
- 解决方法：残差连接 (Skip Connection)
 - 让新增加的层学习浅层网络与深层网络之间的差异（残差），如果恒等映射是最优的，那么直接将残差学习为 0 即可；如果恒等映射不是最优的，网络也可以基于恒等映射轻松地进行小幅调整和优化



三、目标检测

定义：该任务的输入为一张图片，输出包括多个目标的位置信息(矩形框)和对应的类别标签，实现物体定位与分类同步完成

应用：人脸识别、智慧城市、自动驾驶、下游视觉任务

目标检测与图像分类对比

图像分类

- 通常只有一个物体
- 通常位于图像中央
- 通常占据主要面积

目标检测


- 物体数量不固定
- 物体位置不固定
- 物体大小不固定

相同点


- 需要算法“理解”图像的内容 ➡ 采用深度神经网络实现

■ 目标检测的两种基本范式

- 两阶段方法（基于候选区域的方法）：
 - 首先通过特定策略生成候选区域（窗口），随后提取窗口内特征并进行分类与回归，
- 单阶段方法：
 - 直接在特征图空间以单点特征为基础进行密集预测，同时完成分类与回归任务



■ 目标检测技术的演进



目标检测的重要概念：

框：泛指图像上的矩形框、边界横平竖直

边界框：通常指紧密包围感兴趣物体的框

交并比：两矩形框交集面积与并集面积之比，是矩形框重合程度的衡量指标

置信度：模型认可自身预测结果的程度，通常需要为每个框预测一个置信度

非极大值抑制：保留置信度最高的框

■ YOLO 的损失函数

- 多任务学习：回归、分类共同计入损失函数，通过 λ 控制权重
- 定位损失，边界框回归损失：
 - 计算中心坐标与尺寸的损失
- 置信度损失，物体 / 背景预测损失：
 - 边界框预测物体 / 背景时的 object score
- 分类损失，类别预测损失：
 - 边界框预测物体时计算 C 个类别概率的回归损失

四、图像分割

语义分割

目标：将图像中每一个像素划分至对应的语义类别

应用：自动驾驶，人像分割，智能遥感、医疗影像分析

实例分割

全景分割

五、计算机视觉前沿

深度估计、光流估计

目标跟踪，人体姿态估计

视觉推理、视觉基础模型

第1\章 自然语言处理

一、自然语言处理简介

自然语言处理 { 自然语言理解
自然语言生成

二、自然语言处理任务

■ 自然语言处理常见任务

- 词和短语级任务：包括分词、词性标注、命名实体识别、同义词计算等以词为研究对象的任任务。
- 句子和段落级任务：包括文本情感分析、文本相似度计算等以句子为研究对象的任任务。
- 对话和篇章级任务：包括机器阅读理解、对话系统等复杂的自然语言处理系统等。
- 自然语言生成：如机器翻译、机器写作等自然语言生成任任务。

■ 词和短语级任务例子：

分词

小明/和/他/的/朋友/在/北京师范大学/踢/足球


词性标注和命名实体识别

人名 NR CC PN DEG NN P NR NN VV NN
小明 和 他 的 朋友 在 北京 师范大学 踢 足球


指代消解

小明和他朋友在北京师范大学踢足球

句法分析



依存关系分析



三、自然语言处理的基本方法

■ 基于规则的方法：

- 通过人工制定规则来分析和处理语言。这些规则是根据语言的语法和语义设计的，因此它能够精确地处理一些特定的任任务。
- 缺点：当任任务复杂时，规则就会变得很难管理和维护。

■ 基于机器学习的方法：

- 通过让计算机从大量的语言数据中学习规律，而不是手工编写规则。它能够处理一些更加复杂的任任务，并且可以随着数据的增加不断提高性能。
- 缺点：机器学习模型需要大量的数据来训练，且没有很好的可解释性。

- 基于深度学习的方法：
 - 深度学习是机器学习的一种特殊方法，它通过模拟人脑神经网络的方式处理语言。这种方法在处理语言的复杂性和细节上表现得非常好，尤其在大规模数据上，效果往往非常显著。
 - 缺点：计算资源消耗大，并且需要大量的训练时间。
- 基于大模型的方法：
 - 随着大规模语言模型的发展，众多自然语言处理任务都可通过大模型进行处理。大模型能够处理更复杂的语言任务，表现出很高的准确度和灵活性。
 - 缺点：需要极其强大的计算能力，并且训练成本高。

四、语言模型

- 语言模型 (Language Model, LM) 是一种用来对自然语言中的词序列进行建模的数学模型，其主要目标是估计一句话或一段文本出现的概率，从而捕捉语言中的规律与结构。
- 简单来说就是一串词序列的概率分布，本质上是在回答一个问题：出现的语句是否合理。



- 统计语言模型——N元 (N-gram) 语言模型：
 - 在实践中，如果文本的长度较长， $P(w_i|w_1, \dots, w_{i-1})$ 的估算会非常困难。因此，研究者们提出使用一个简化模型：N元模型。
 - 假设句子中一个词出现的可能性，仅仅取决于它前面的 N-1 个词。基于该假设，计算下一个词出现的概率可以简化为：

$$P(w_i|w_1, \dots, w_{i-1}) \approx P(w_i|w_{i-N+1}, \dots, w_{i-1})$$

可以通过统计N元 $w_{i-N+1}, \dots, w_{i-1}, w_i$ 和 (N-1) 元 $w_{i-N+1}, \dots, w_{i-1}$ 在文档集合中出现的频次 (count) 近似计算：

$$P(w_i|w_{i-N+1}, \dots, w_{i-1}) = \frac{\text{count}(w_{i-N+1}, \dots, w_{i-1}, w_i)}{\text{count}(w_{i-N+1}, \dots, w_{i-1})}$$

我/喜欢/苹果	一元	频次	二元	频次
我/喜欢/香蕉	我	3	我/喜欢	2
他/喜欢/香蕉	喜欢	3	他/喜欢	1
我/吃/苹果	苹果	2	喜欢/苹果	1
	香蕉	2	喜欢/香蕉	2
	他	1	我/吃	1
	吃	1	吃/苹果	1

$$P(\text{喜欢}|\text{我}) = \frac{\text{count}(\text{我/喜欢})}{\text{count}(\text{我})} = \frac{2}{3}, \quad P(\text{吃}|\text{我}) = \frac{\text{count}(\text{我/吃})}{\text{count}(\text{我})} = \frac{1}{3},$$
$$P(\text{喜欢}|\text{他}) = \frac{\text{count}(\text{他/喜欢})}{\text{count}(\text{他})} = \frac{1}{1}, \quad P(\text{苹果}|\text{喜欢}) = \frac{\text{count}(\text{喜欢/苹果})}{\text{count}(\text{喜欢})} = \frac{1}{3}$$


计算给定“我/喜欢”，下一个词为“香蕉”的概率？

大语言模型训练方法：

预训练 → 监督微调 → 基于人类反馈的强化学习


第九章 生成式人工智能

一、人工智能生成内容




生成模型的工作原理

- 思想：学习数据的潜在概率分布 $p(x)$ ，并基于该分布生成新的、与训练数据具有相似特征的内容
 - **数据分布建模**：通过神经网络来学习输入数据的统计特征和结构规律，也就是所谓的数据分布，即通过学习 $p_{model}(x)$ 来近似训练数据的分布 $p_{data}(x)$
 - **从分布中采样**：通过“采样”等方式，生成新的内容，这些内容没有直接出现在训练数据中，但在风格或结构上具有高度相似性



生成模型的应用场景



二、基于 GAN 的内容生成

生成对抗网络 (GAN)

- 生成对抗网络 (Generative adversarial network, GAN)
 - 由 Ian Goodfellow 等人于2014年提出的一种生成模型，该模型可视为两个神经网络相互竞争的零和游戏 (zero-sum game)，最终达到纳什均衡
 - 组成部分：生成器 (Generator, 简称 G)、判别器 (Discriminator, 简称 D)
- 生成器 G
 - 为了能够让生成的数据以假乱真，需要理解真实数据的分布
 - 隐式建模真实数据的分布
- 判别器 D
 - 能够有效区分真假，从而帮助生成器不断提升生成数据的真实性

对抗思想

- G 负责从随机噪声中生成数据， D 负责判断这些数据是真实数据还是 G 生成的假数据。
- **核心思想**：通过生成器和判别器之间的竞争对抗，不断提升彼此水平，训练生成器生成以假乱真的数据，使得生成的数据分布逼近真实数据分布。

GAN 损失函数

- 最小-最大优化问题：寻找判别器 D 最大化 $V(D, G)$ ；生成器 G 最小化 $V(D, G)$ 。
 - 判别器 θ_d ：最大化目标，以便 $D(x)$ 接近于1（真实样本）， $D(G(z))$ 接近于0（虚造样本）
 - 生成器 θ_g ：最小化目标，以便 $D(G(z))$ 接近于1（尝试骗过判别器）

交叉熵损失函数

判断数据 x 是真实数据的概率（1为真）

根据随机噪声 z ，生成数据

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

Generator objective

Discriminator objective

GAN 的训练

- 具体实现：交替优化判别器与生成器网络
 - 先固定生成器 G ，训练判别器 D ：尽可能准确分辨真假样本
 - 再固定判别器 D ，训练生成器 G ：提高造假能力，让生成样本欺骗判别器

GAN的应用：人脸生成、图像插值，图像修复与编辑，
图像风格迁移，图像超分辨率、三维数据生成

GAN 的问题与改进

- **网络训练不稳定、难以达到均衡点**：因为生成器与判别器的 min-max 对抗博弈难以同时收敛，训练过程容易出现梯度消失或震荡。
- **模式崩溃**：生成器只输出少数几种样本以“欺骗”判别器，导致生成结果缺乏多样性。
- 改进损失函数：Wasserstein GAN (WGAN) 等
- 改进判别器或生成器结构：Spectral Normalization GAN (SN-GAN) 等
- 使用辅助信息条件：condition-GAN (cGAN) 等

三、基于扩散模型的生成

扩散模型是一类新型的生成模型，用于从噪声还原数据

思路：分步构建，于是扩散模型有两个基本过程：

- 正向过程 (Forward Diffusion)：也叫前向扩散，给数据逐步加噪，直到接近纯噪声
- 逆向过程 (Reverse Diffusion)：也叫逆向扩散，从噪声逐步去噪，恢复原始数据

扩散模型的应用: 文本生成图像, 图像生成图像

图像风格迁移, 基于 IP 的扩展生成, 故事生成, 实时生成

图像可控生成, 风格保持, 图像生成视频, 虚拟试衣

问题与改进

- 问题
 - 速度慢
 - 生成一张图需要去噪 20-50 步，耗时几秒到十几秒。
 - 算力贵
 - 普通用户的电脑跑起来很吃力，难以在手机端部署。
 - 细节不可控
 - AI 经常“听不懂人话”，比如分不清“左边是猫，右边是狗”；手指、文字拼写依然容易出错（幻觉）。
- 一些改进思路
 - 快速推理：LCM (Latent Consistency Models) 或 Turbo 技术
 - 架构升级：DiT (Diffusion Transformers) 等
 - 精细控制：插件化 (Adapters / ControlNet)

四、多模态大模型及应用

属性	单模态	多模态
数据丰富性	单一信息源	多信息源
鲁棒性	单一模态的数据质量可能会影响整体性能	可以通过其他模态补偿某个模态的不足
决策准确性	决策基于单一信息源可能受限	综合各种信息决策更为准确
处理复杂性	处理流程相对简单	需要处理和融合各种模态的数据复杂性增加
信息冗余	无法从其他模态中获取冗余信息	可能从不同模态中获取重复冗余的信息
上下文理解	上下文理解可能受限于单一信息源	能够结合多种信息更好地理解上下文
特征维度	特征维度相对较低	由于融合了多种信息源特征维度可能会更高
可解释性	由于只有一个信息源可能更易于解释	多种信息源的融合可能会降低模型的可解释性
数据同步	不需要考虑不同模态之间的同步问题	需要确保不同模态的数据是同步的
计算资源	计算资源需求相对较低	需要更多的计算资源处理和融合多种模态数据

多模态融合是指将来自多个不同类型（例如文本、图像、声音等）的数据合并，利用跨模态技术产生一个综合的数据表示或输出，代表一种全新、流畅和高效的人类交互体验，其核心挑战是如何有效地融合这些模式以提供连贯和有意义的输出。

自注意力机制的本质: 捕捉序列内部的依赖关系

CLIP：图文对齐的范式模型

- 以图片生成为例来看多模态大模型
 - 在多模态大模型中，一个核心问题是：不同模态的数据，如何在语义层面对齐 (alignment)?
 - CLIP （Contrastive Language–Image Pretraining）把图像和文本学到一个共享语义空间，为后续几乎所有多模态任务提供“对齐能力”。

- 大规模数据预训练：互联网上数以亿计的“图片+描述”对
- 通过对比学习进行训练：
 - 拉近：让正确的图文对（如：猫的图+“一只猫”的文字）在语义空间里靠得最近。
 - 推开：让不匹配的图文对（如：狗的图+“一只猫”的文字）距离最远。
- 意义：赋予了计算机一种“常识”，它不仅认识具体的猫，还理解了“猫”这个概念在不同语境下的视觉表现。

CLIP的革命式意义：统一表示，赋能下游



单选多选30题2分
判断题10题1分
简答题3题10分